

Modelo de IA para el diagnóstico temprano de enfermedades en maíz a partir de imágenes de hojas

Emersson Elian Lopez Pita - 2225507
Cesar Alejandro Soto Paipa - 2225612
Juan David Mena Gamboa - 2221886



GRUPO N. 7

LET'S
START



www.reallygreatsite.com



Problemática



GRUPO N. 7



- Cultivos clave para economía y seguridad alimentaria



- Enfermedades afectan la productividad



- Diagnóstico actual depende de expertos → costoso y poco accesible

NEXT
SLIDE



Objetivo del modelo IA

- Detectar si una hoja está enferma
- Identificar la enfermedad específica
- Trabajo enfocado en una especie/enfermedad concreta



NEXT
SLIDE



A photograph of two farmers in a field. The farmer on the left is wearing a straw hat and a red and blue checkered shirt, looking down at a plant. The farmer on the right is wearing a white hat and a pink shirt, also looking down. The background is a blurred field of green plants under a bright sky.

Cómo funcionará el modelo

- **Paso 1: La IA compara la imagen con ejemplos que ya tiene guardados el dataset**
- **Paso 2: El sistema dice si la hoja está sana o enferma.**
- **Paso 3: Si está enferma, indica qué enfermedad específica es.**

NEXT
SLIDE

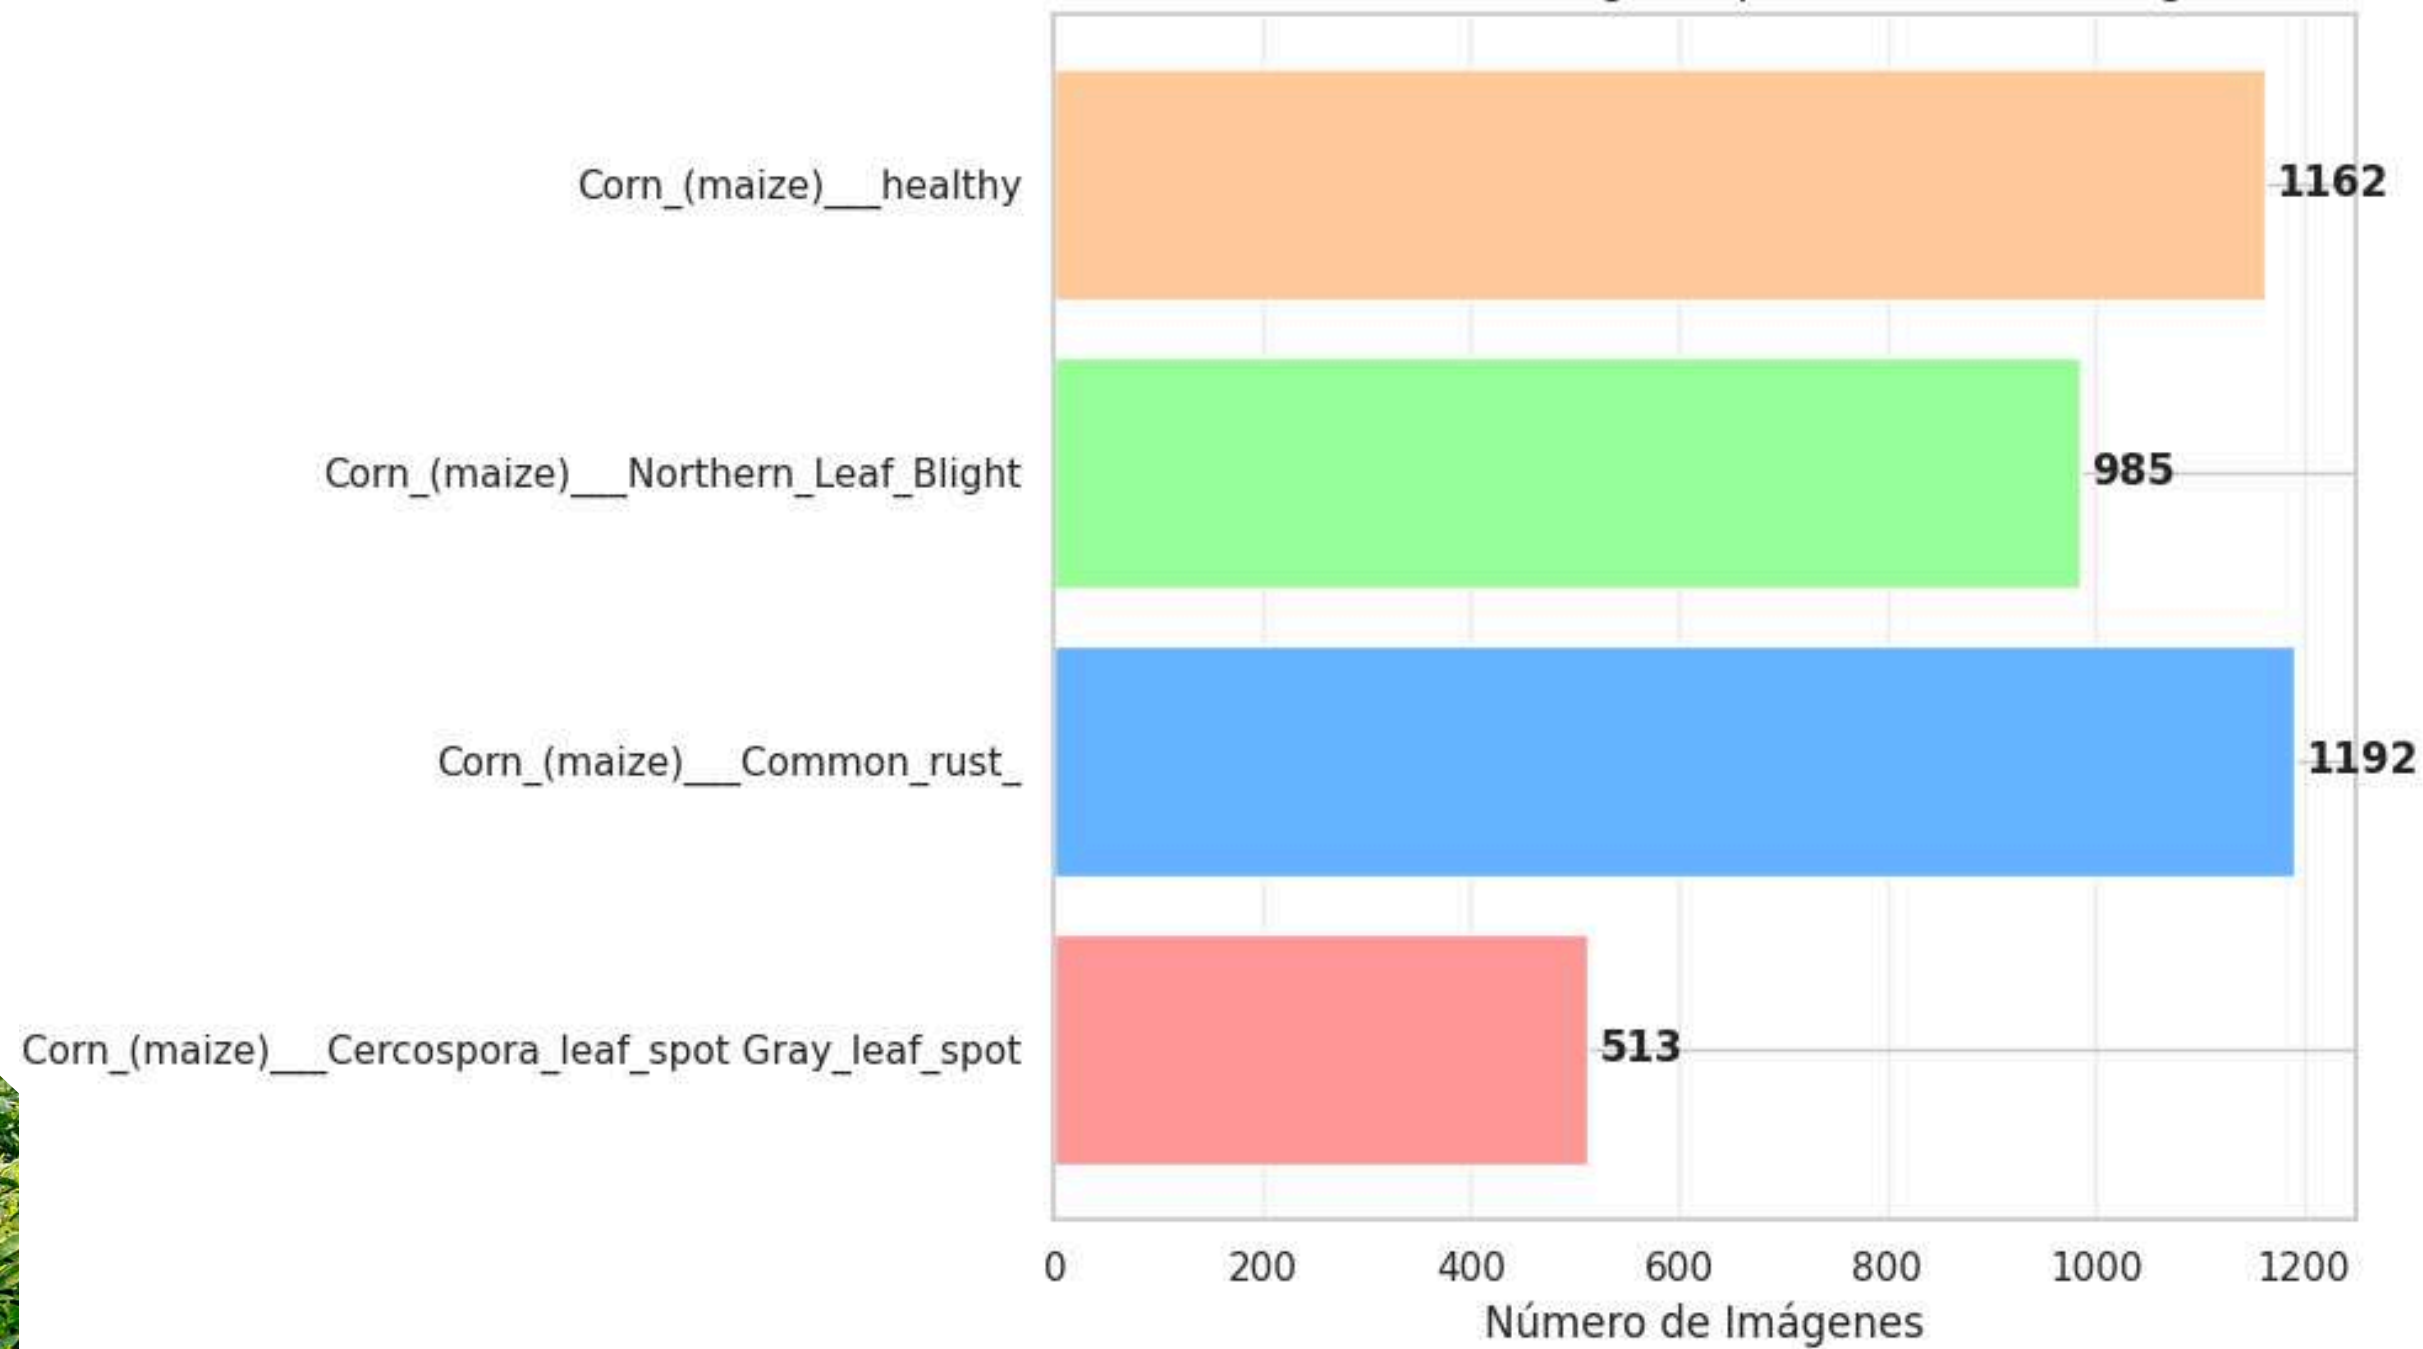


Dataset



GRUPO N. 7

Distribución de Imágenes por Clase - PlantVillage



Distribución Porcentual de Clases

100%

NEXT
SLIDE



Dataset

Distribución Porcentual de Clases

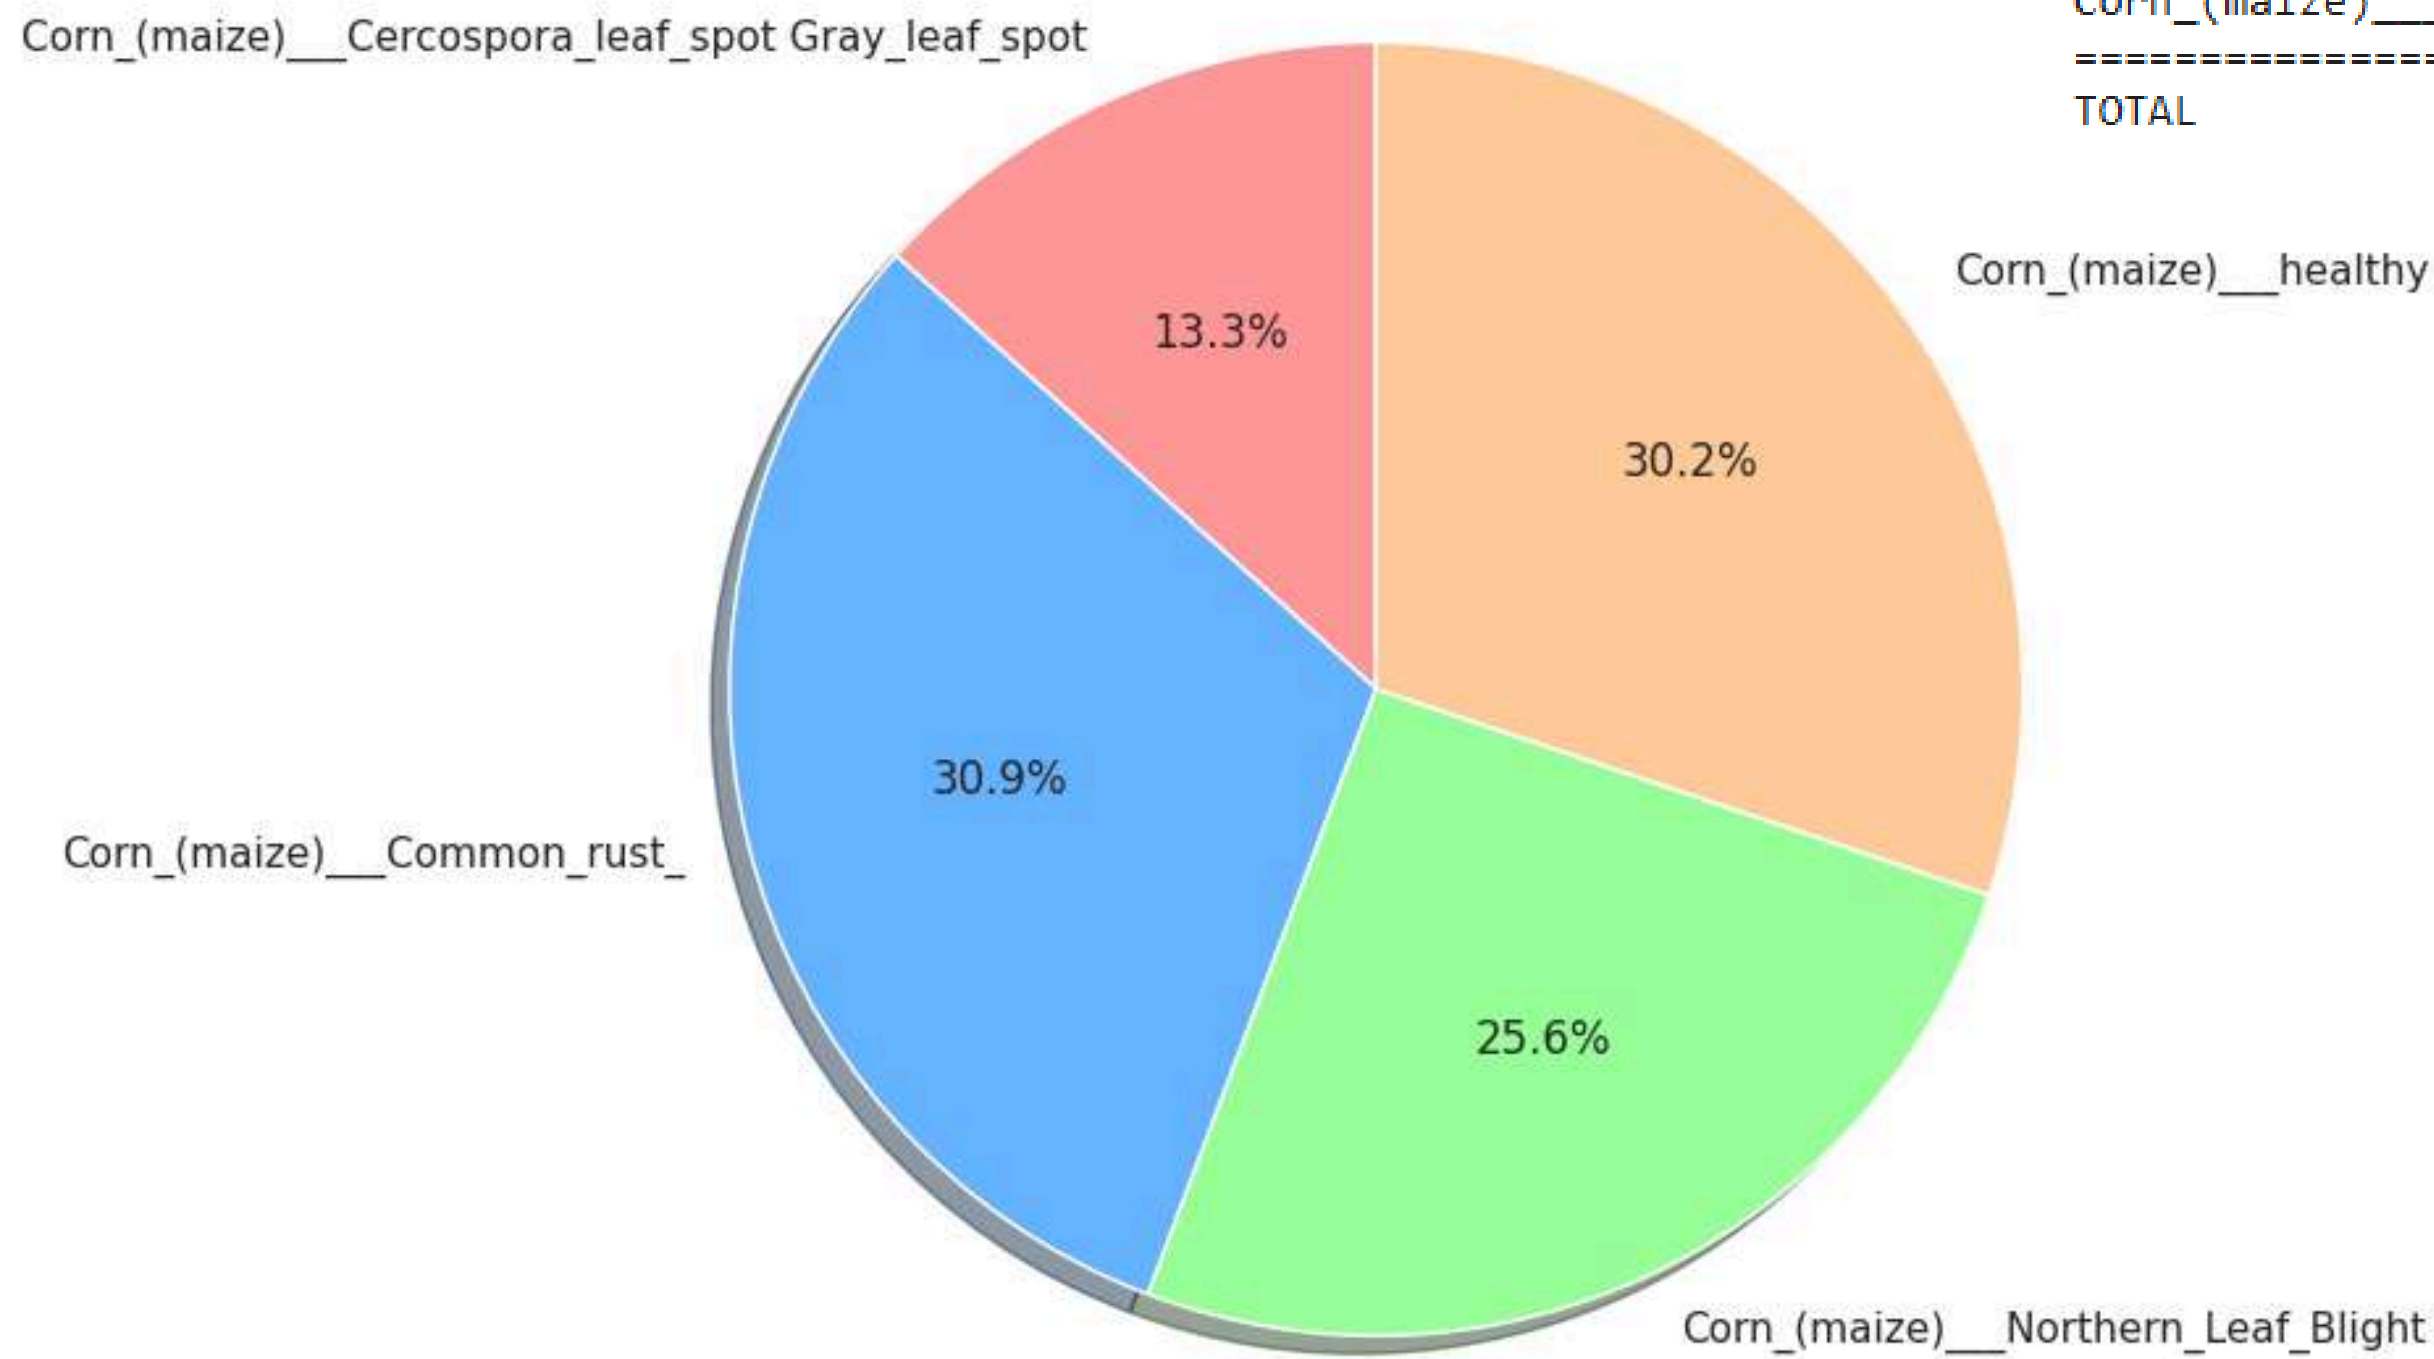


TABLA RESUMEN DEL DATASET:

CLASE	IMÁGENES	%
Corn_(maize)___Cercospora_leaf_spot Gray_leaf_spot	513	13.32
Corn_(maize)___Common_rust_	1192	30.94
Corn_(maize)___Northern_Leaf_Blight	985	25.57
Corn_(maize)___healthy	1162	30.17
TOTAL	3852	100%

100%

NEXT
SLIDE



Classes

Hoja Sana



Common
Rust



Northern
Leaf Blight



Cercospora
Leaf Spot
(Gray Leaf Spot)



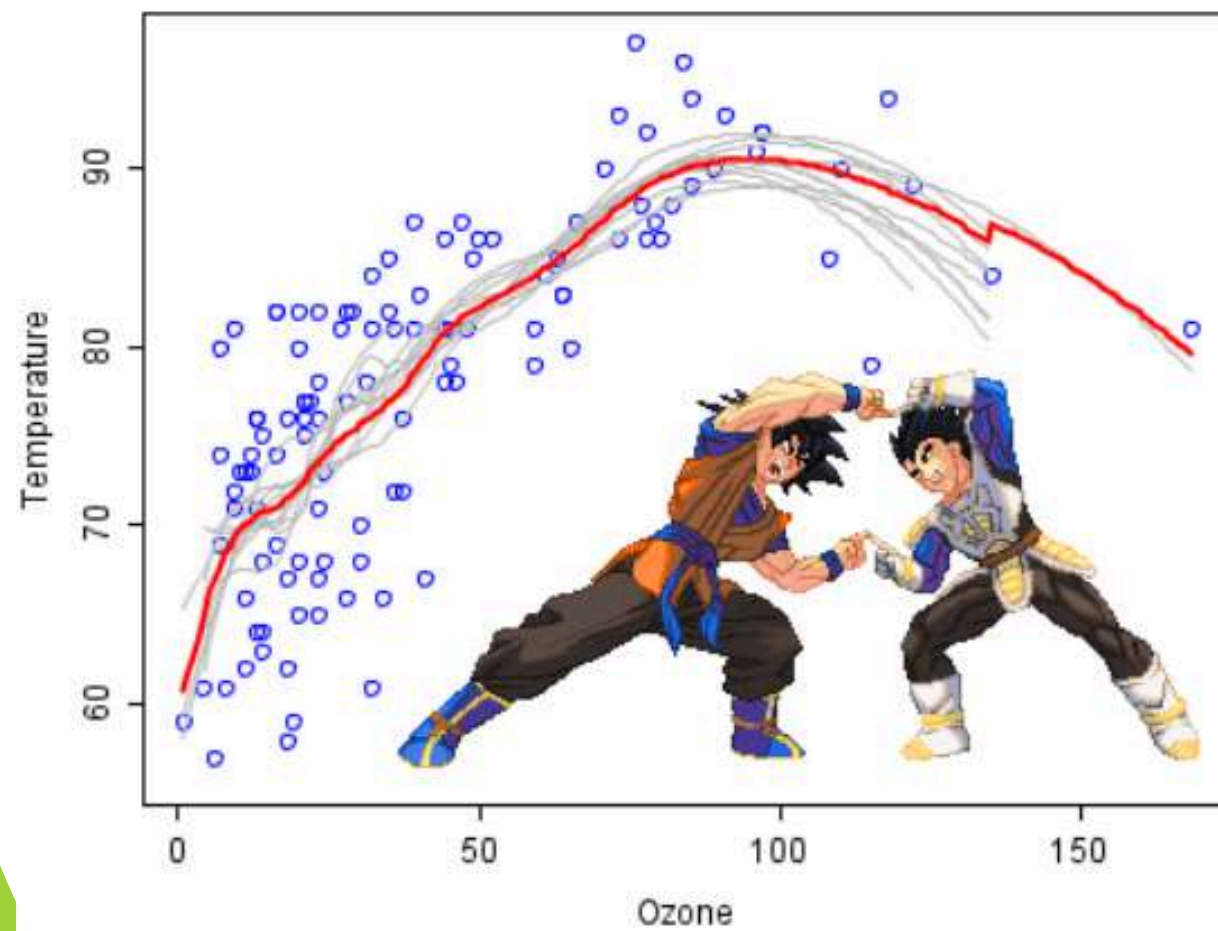


Problema de modelo

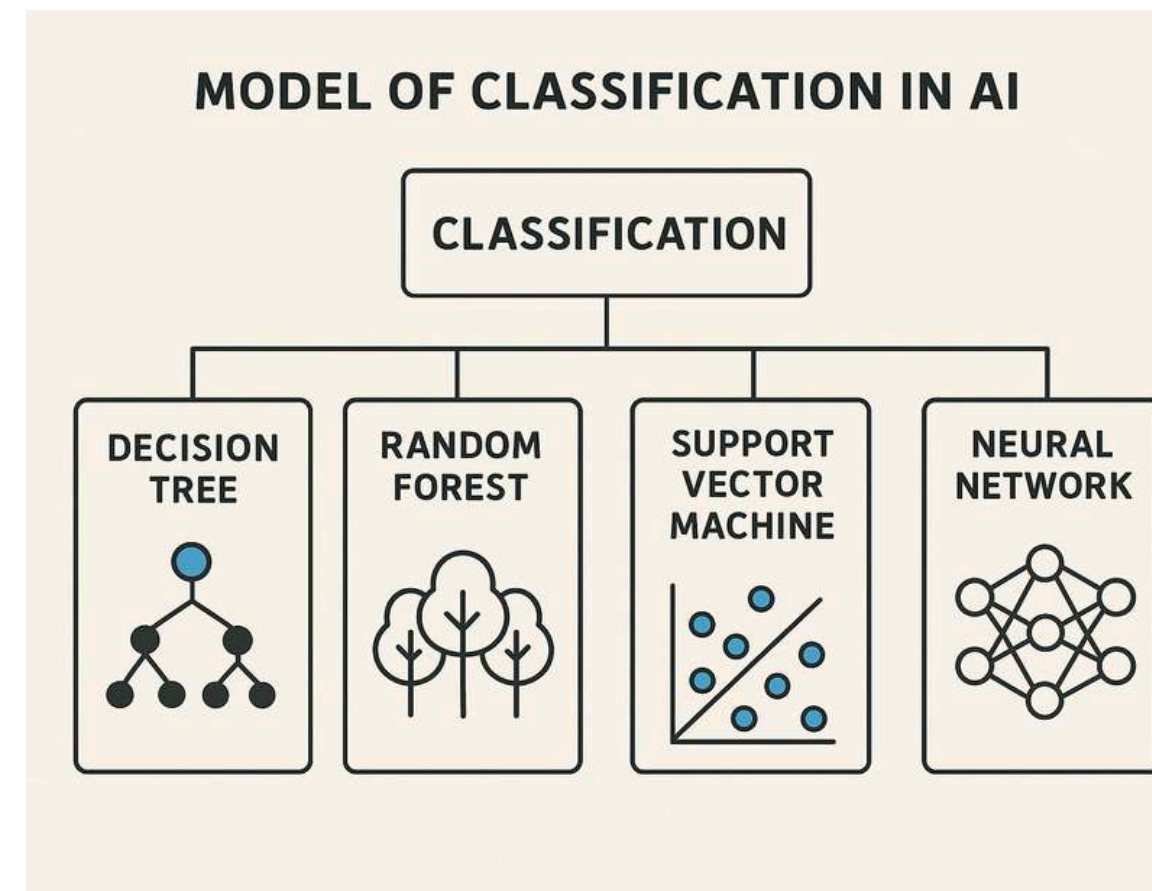


GRUPO N. 7

- Modelo de Regresion



- Modelo de Clasificación



NEXT SLIDE



Analisis con ML

- Preparación de datos y extracción de características

```
img_path = os.path.join(folder, file)
img = Image.open(img_path).convert("RGB").resize((64,64))
arr = np.array(img)/255.0
mean = arr.mean(axis=(0,1))
std = arr.std(axis=(0,1))
features = np.concatenate([mean,std])
data.append([*features, label])
```

- Distribución de las clases

Cantidad de imágenes por clase:

label	
Corn_(maize)___Common_rust_	1192
Corn_(maize)___healthy	1162
Corn_(maize)___Northern_Leaf_Blight	985
Corn_(maize)___Cercospora_leaf_spot Gray_leaf_spot	513



NEXT
SLIDE



Train Test

```
▶ X = df.drop('label', axis=1)
  y = df['label']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, stratify=y, random_state=42
)

scaler = StandardScaler() # Esto es para normalizar
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

print("Tamaño train:", X_train.shape, " | Tamaño test:", X_test.shape)
```

⇒ Tamaño train: (2696, 6) | Tamaño test: (1156, 6)

- Modelos comparados

```
models = {
    "Decision Tree": DecisionTreeClassifier(),
    "Random Forest": RandomForestClassifier(),
    "SVM": SVC()
}
```



NEXT
SLIDE






Comparación de Accuracy



GRUPO N. 7

Comparación de precisión entre modelos ML



NEXT
SLIDE



K-Fold

```
kf = KFold(n_splits=5, shuffle=True, random_state=42)
```

```
for name, model in models.items():  
    scores = cross_val_score(model, X_train_scaled, y_train, cv=kf, scoring='accuracy')  
    print(f"{name} | Accuracy promedio (5-fold): {scores.mean():.3f} ± {scores.std():.3f}")
```

Decision Tree | Accuracy promedio (5-fold): 0.812 ± 0.014

Random Forest | Accuracy promedio (5-fold): 0.861 ± 0.006


SVM | Accuracy promedio (5-fold): 0.872 ± 0.010



NEXT
SLIDE



Matriz de confusion



GRUPO N. 7

NEXT
SLIDE

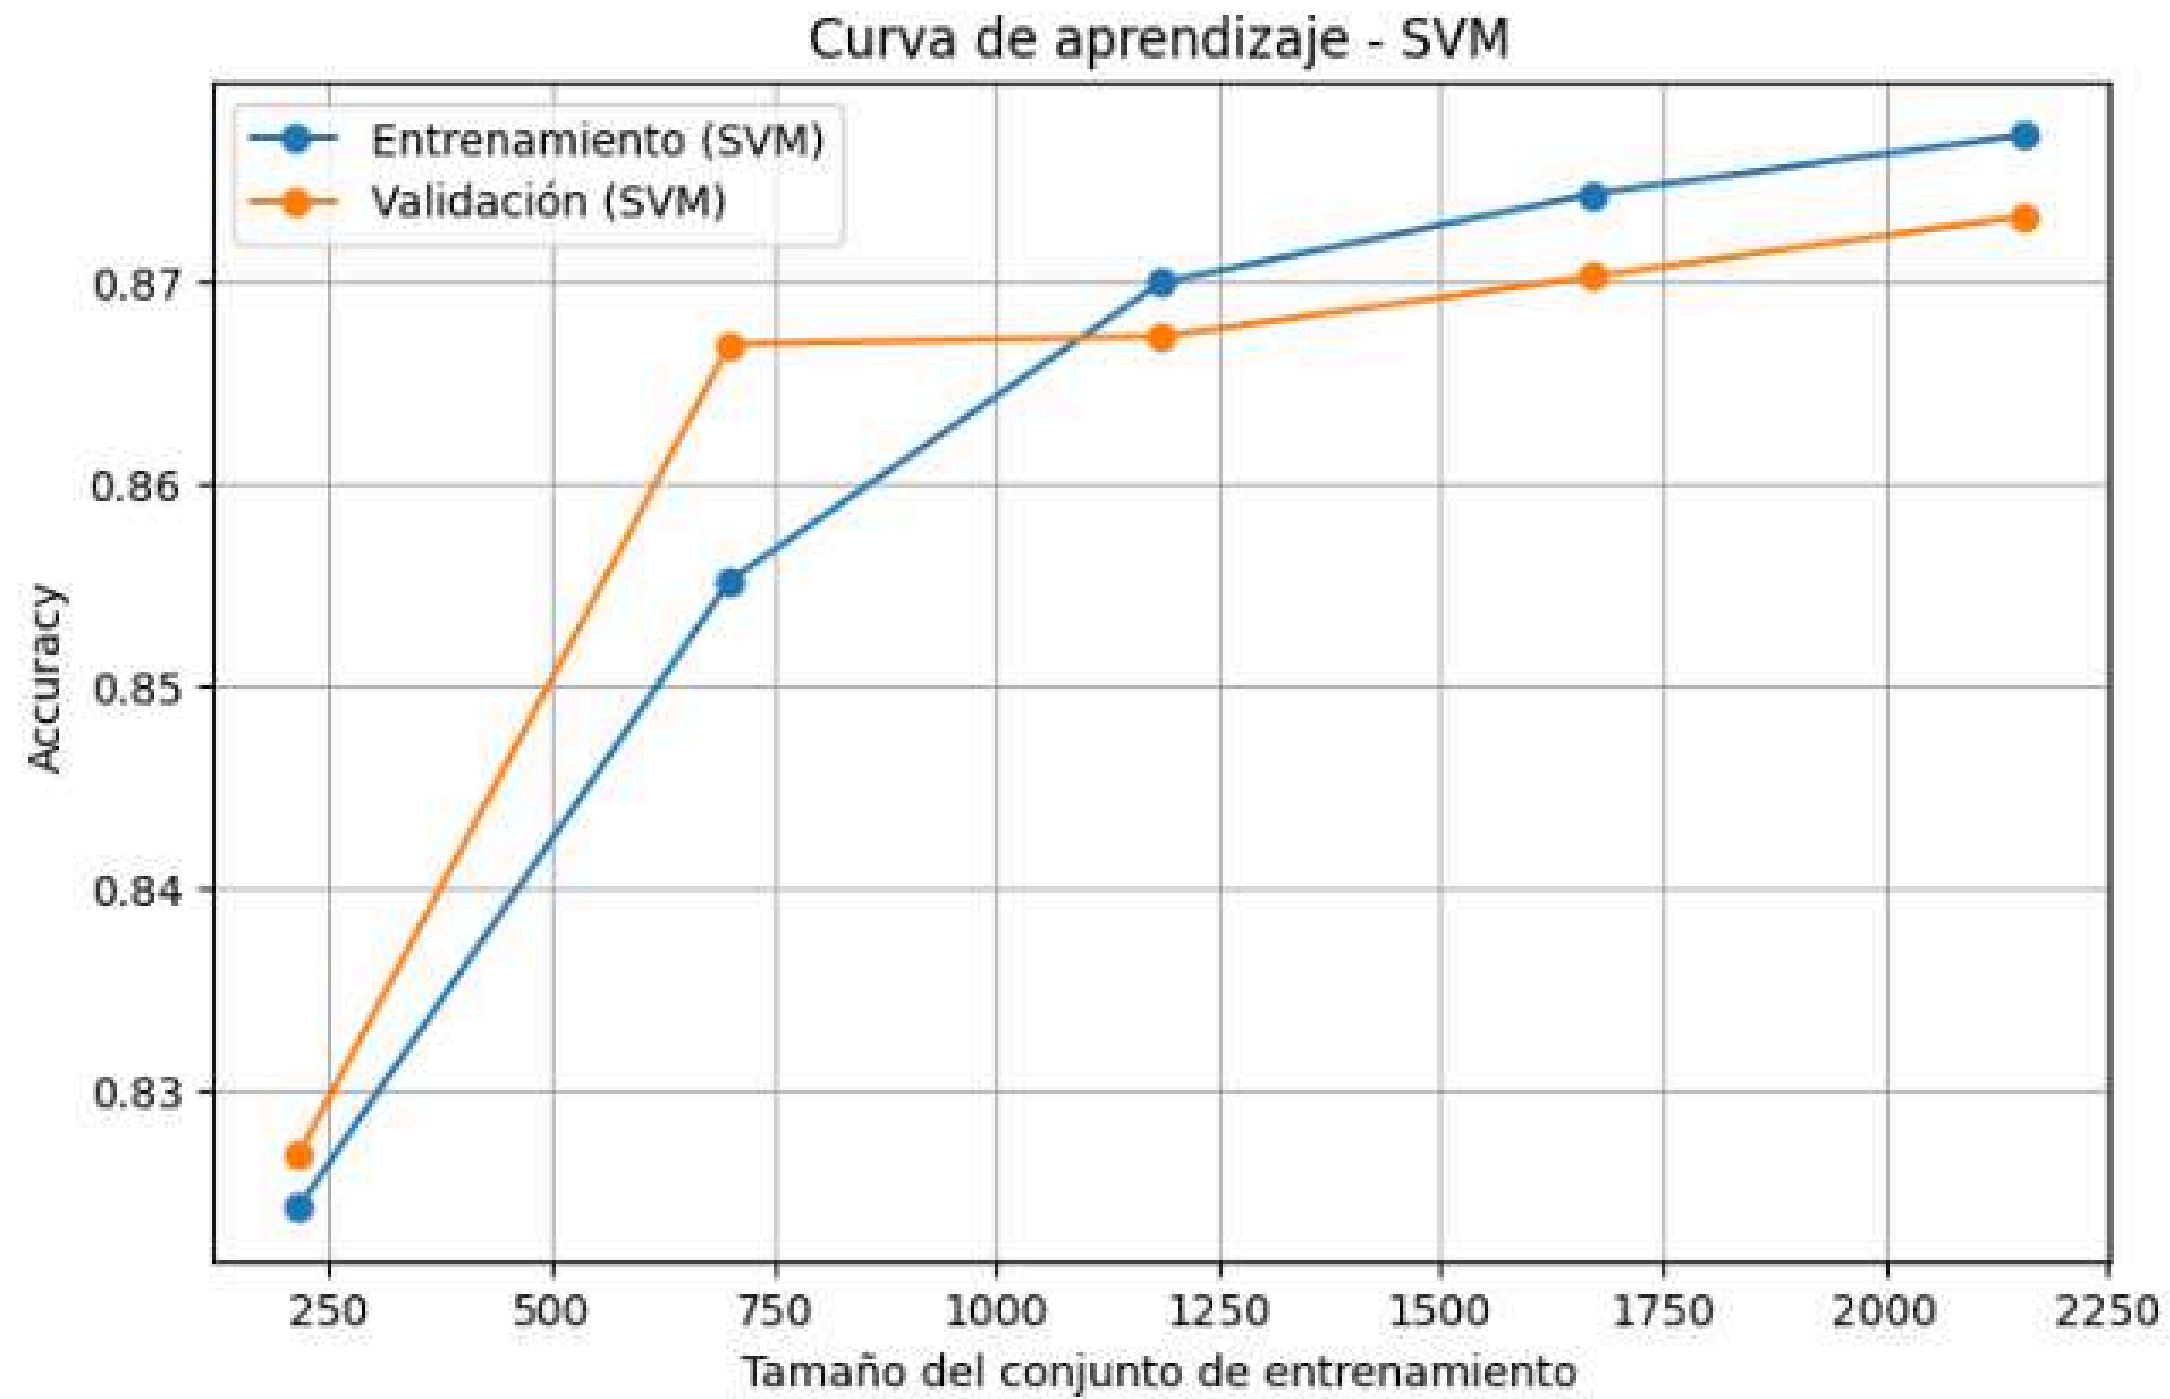




Curva de aprendizaje



GRUPO N. 7



NEXT
SLIDE






Curva de aprendizaje



GRUPO N. 7



NEXT
SLIDE

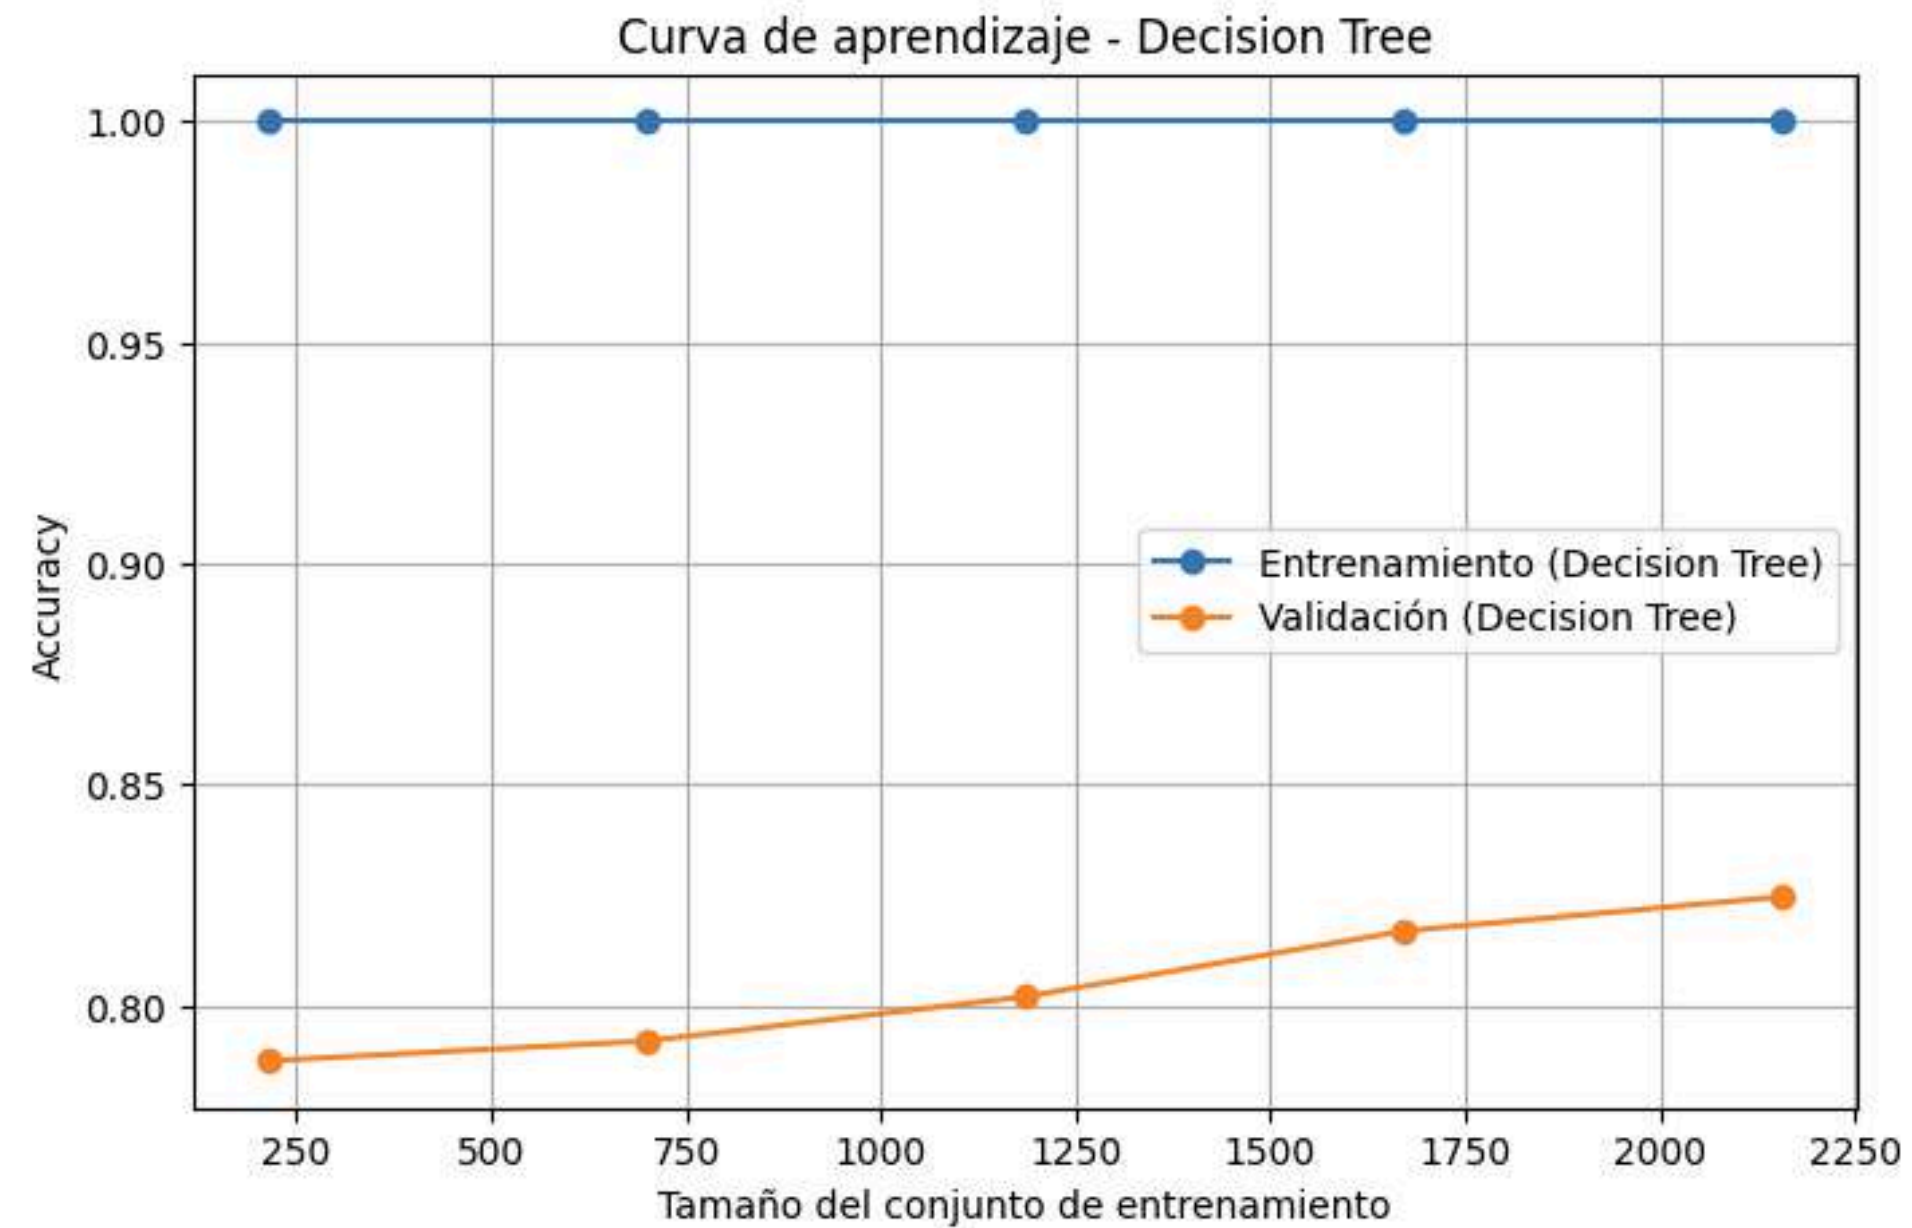




Curva de aprendizaje



GRUPO N. 7



NEXT
SLIDE



**MOVING FROM
ML
→
DEEP LEARNING**




GRUPO N. 7

**LET'S
START**



Enfoque con Deep Learning

Multilayer Perceptron (MLP) Neural Networks



Estructura de una imagen digital



INGOUDE
COMPANY



“Estas matrices son la entrada del modelo de Deep Learning. Mientras los modelos de Machine Learning tradicional necesitan extraer características manualmente (color, textura, forma), el modelo de red neuronal aprende directamente de los valores de estos píxeles.”


Verificación de Dimensiones de Imágenes

```
import os
from PIL import Image

# Obtener lista de archivos de imagen
extensiones_validas = ('.jpg', '.jpeg', '.png', '.bmp', '.tiff', '.JPG', '.JPEG', '.PNG')
archivos_imagen = [f for f in os.listdir(directorio) if f.endswith(extensiones_validas)]

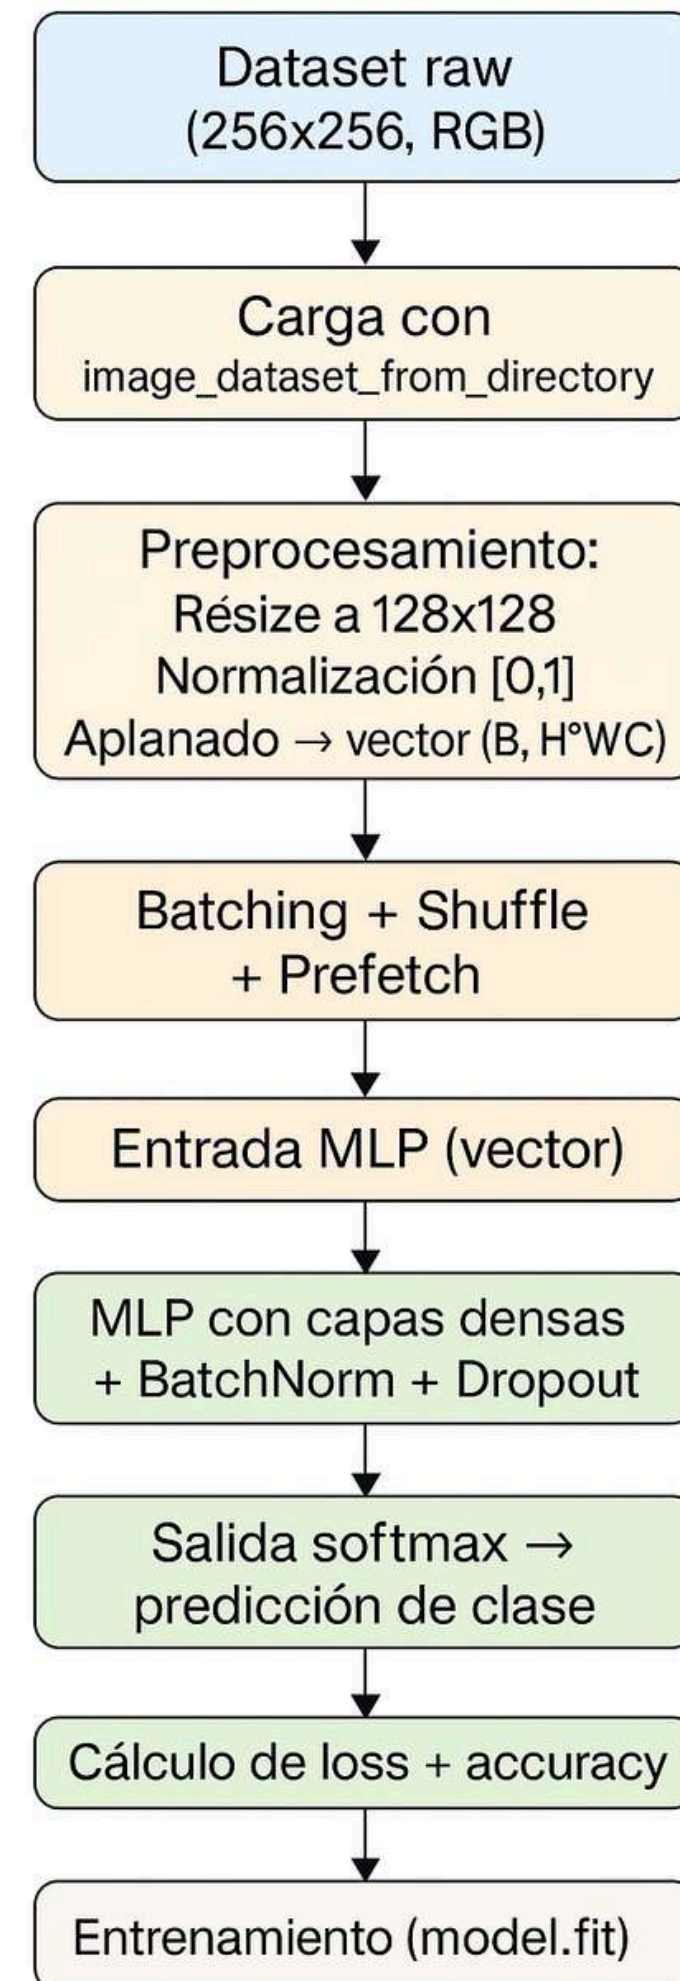
if not archivos_imagen:
    return {"error": "No se encontraron archivos de imagen en el directorio"}

# Verificar cada imagen
dimensiones_encontradas = set()
imagenes_problematicas = []
total_imagenes = len(archivos_imagen)
```



Entrenamiento del Modelo Clasificador

```
Found 3852 files belonging to 4 classes.
Using 3082 files for training.
Found 3852 files belonging to 4 classes.
Using 770 files for validation.
Orden de clases (fijo): ['Corn_(maize)___Cercospora_leaf_spot Gray_leaf_spot', 'Corn_(maize)___Common_rust_', 'Corn_(maize)___healthy', 'Corn_(maize)___Northern_Leaf_Blight']
Distribución clases (train): {'Corn_(maize)___Cercospora_leaf_spot Gray_leaf_spot': 427, 'Corn_(maize)___Common_rust_': 942, 'Corn_(maize)___healthy': 950, 'Corn_(maize)___Northern_Leaf_Blight': 763}
Class weights: {0: 7.217798594847775, 1: 3.2717622080679405, 2: 3.2442105263157894, 3: 4.039318479685452}
Epoch 1/10
97/97 ————— 51s 497ms/step - accuracy: 0.7579 - loss: 3.0762 - val_accuracy: 0.1558 - val_loss: 2.7370 - learning_rate: 0.0010
Epoch 2/10
97/97 ————— 47s 489ms/step - accuracy: 0.8381 - loss: 2.2144 - val_accuracy: 0.6727 - val_loss: 1.1200 - learning_rate: 0.0010
Epoch 3/10
97/97 ————— 83s 494ms/step - accuracy: 0.8621 - loss: 2.0062 - val_accuracy: 0.7974 - val_loss: 0.9811 - learning_rate: 0.0010
Epoch 4/10
```





Evaluación y Predicción de Imágenes con el Modelo Entrenado



GRUPO N. 7



```
reg = tf.keras.regularizers.l2(1e-4)
model = tf.keras.Sequential([
    # Primera capa necesita input_shape
    tf.keras.layers.BatchNormalization(input_shape=(target_size[0]*target_size[1]*3,)),
    tf.keras.layers.Dense(1024, activation="relu", kernel_regularizer=reg),
    tf.keras.layers.BatchNormalization(),
    tf.keras.layers.Dropout(0.4),
    tf.keras.layers.Dense(512, activation="relu", kernel_regularizer=reg),
    tf.keras.layers.BatchNormalization(),
    tf.keras.layers.Dropout(0.3),
    tf.keras.layers.Dense(128, activation="relu", kernel_regularizer=reg),
    tf.keras.layers.BatchNormalization(),
    tf.keras.layers.Dropout(0.2),
    tf.keras.layers.Dense(num_classes, activation="softmax")
])
```

NEXT
SLIDE



Algunas Pruebas



INGOUDE
COMPANY

```
test_loss, test_acc = model_infer.evaluate(val_ds_raw, verbose=1)
```

25/25 ————— 2s 70ms/step - accuracy: 0.9273 - loss: 0.7095

Test loss: 0.7095332741737366

Test accuracy: 0.9272727370262146

Algunas Pruebas



INGOUDE
COMPANY

```
In [12]: dataset_path = "plantvillage dataset/color"
vegetable_leaf = "Corn_(maize)___Cercospora_leaf_spot Gray_leaf_spot"
specific_img = "00a20f6f-e8bd-4453-9e25-36ea70feb626__R5_GLSp_4655.JPG"
early_blight = os.path.join(dataset_path, vegetable_leaf, specific_img)
# Ejecuto
predict_external_image(early_blight)
```

Pred: Corn_(maize)___Northern_Leaf_Blight (p=0.88)



```
Probs: {'Corn_(maize)___Cercospora_leaf_spot Gray_leaf_spot': 0.1215328574180603, 'Corn_(maize)___Common_rust_': 0.0001279489
0790246427, 'Corn_(maize)___healthy': 1.767093999660574e-05, 'Corn_(maize)___Northern_Leaf_Blight': 0.8783215284347534}
```

```
Out[12]: ('Corn_(maize)___Northern_Leaf_Blight',
array([1.2153286e-01, 1.2794891e-04, 1.7670940e-05, 8.7832153e-01],
dtype=float32))
```


Algunas Pruebas



INGOUDE
COMPANY

In [13]:

```
dataset_path = "plantvillage dataset/color"  
vegetable_leaf = "Corn_(maize)___Common_rust_"  
specific_img = "RS_Rust_1563.JPG"  
  
late_blight = os.path.join(dataset_path, vegetable_leaf, specific_img)  
  
predict_external_image(late_blight)
```


Pred: Corn_(maize)___Common_rust_ (p=1.00)



Probs: {'Corn_(maize)___Cercospora_leaf_spot Gray_leaf_spot': 2.6803040782397147e-06, 'Corn_(maize)___Common_rust_': 0.9999971389770508, 'Corn_(maize)___healthy': 1.9731347222773366e-08, 'Corn_(maize)___Northern_Leaf_Blight': 9.820931978765657e-08}

Out[13]: ('Corn_(maize)___Common_rust_',
array([2.6803041e-06, 9.9999714e-01, 1.9731347e-08, 9.8209320e-08],
dtype=float32))

LENGUAJE NO SUPERVISADO



Metodos Usados



GRUPO N. 7

=== EVALUACIÓN CON MÉTRICAS ===
EVALUANDO MÉTRICAS DE CALIDAD...

KMEANS:

- Clusters encontrados: 4
- Adjusted Rand Index: 0.707
- Silhouette Score: 0.471

DBSCAN:

- Clusters encontrados: 1
- Adjusted Rand Index: 0.000
- Silhouette Score: -1.000

AGGLOMERATIVE:

- Clusters encontrados: 4
- Adjusted Rand Index: 0.727
- Silhouette Score: 0.461



MEJOR MÉTODO: Agglomerative (ARI: 0.727)

NEXT
SLIDE

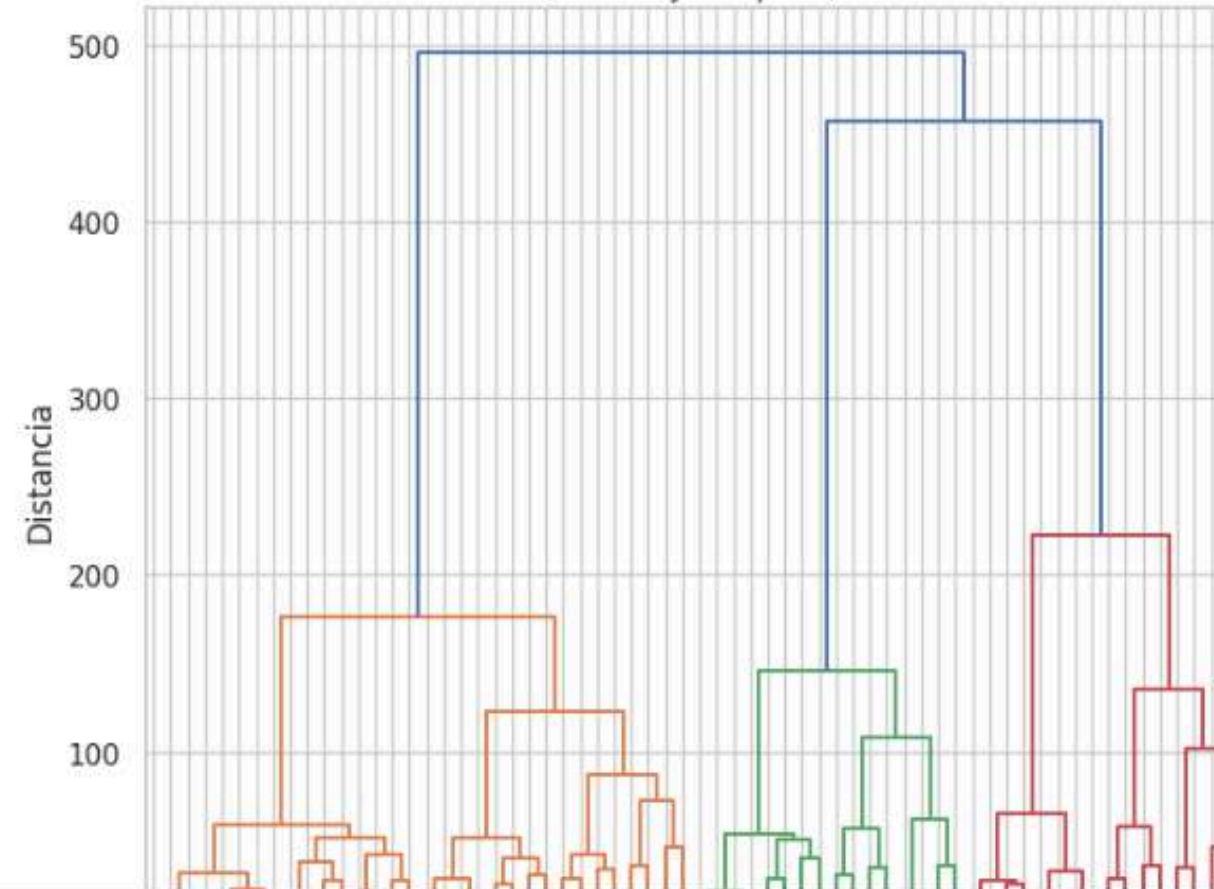


Representacion Grafica


AGGLOMERATIVE CLUSTERING
ARI: 0.727




DENDROGRAMA
(Cluster Jerárquico)




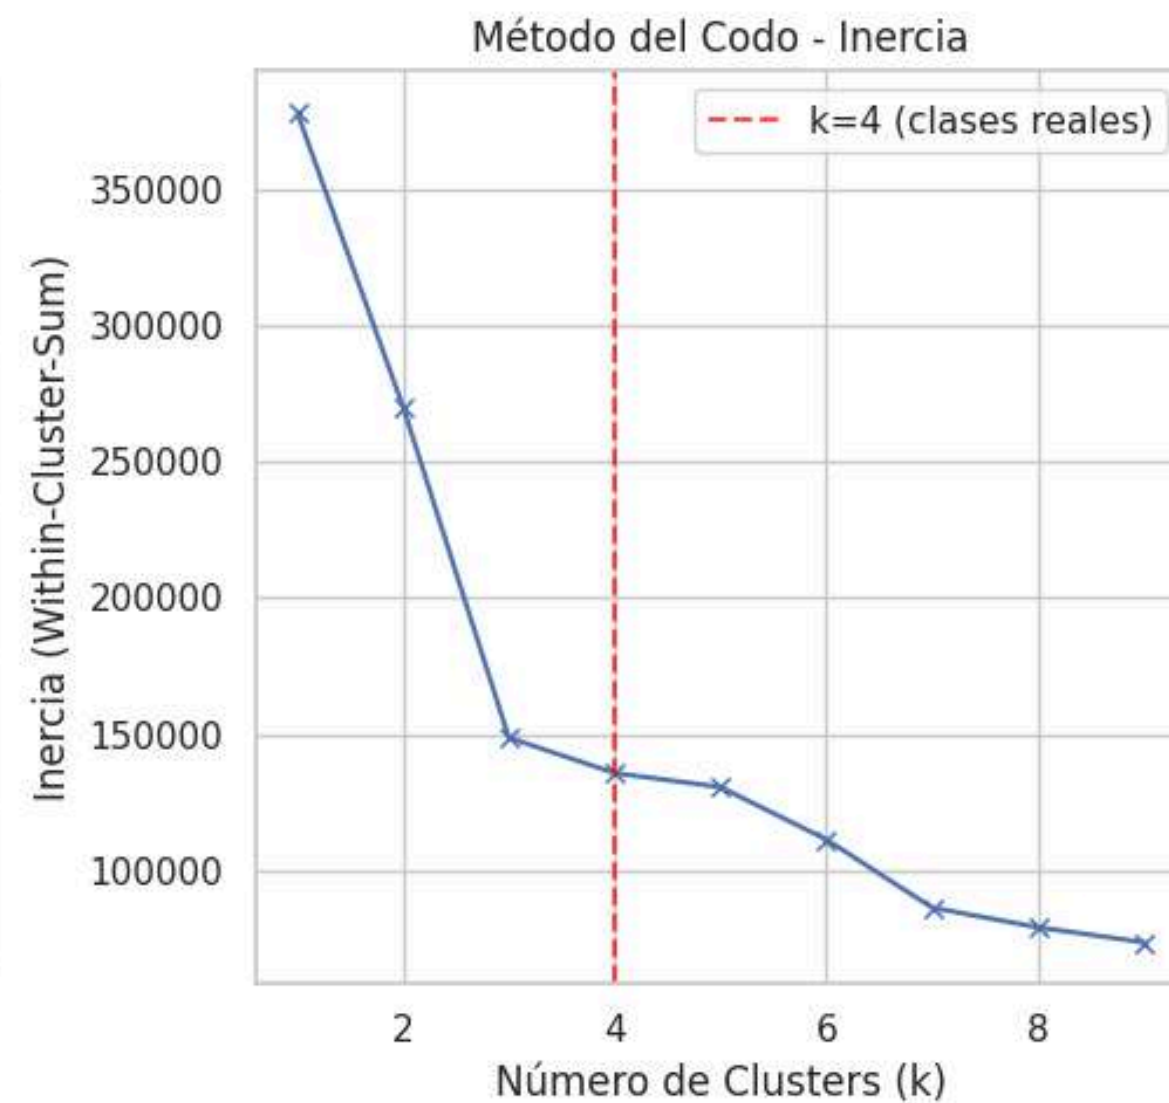
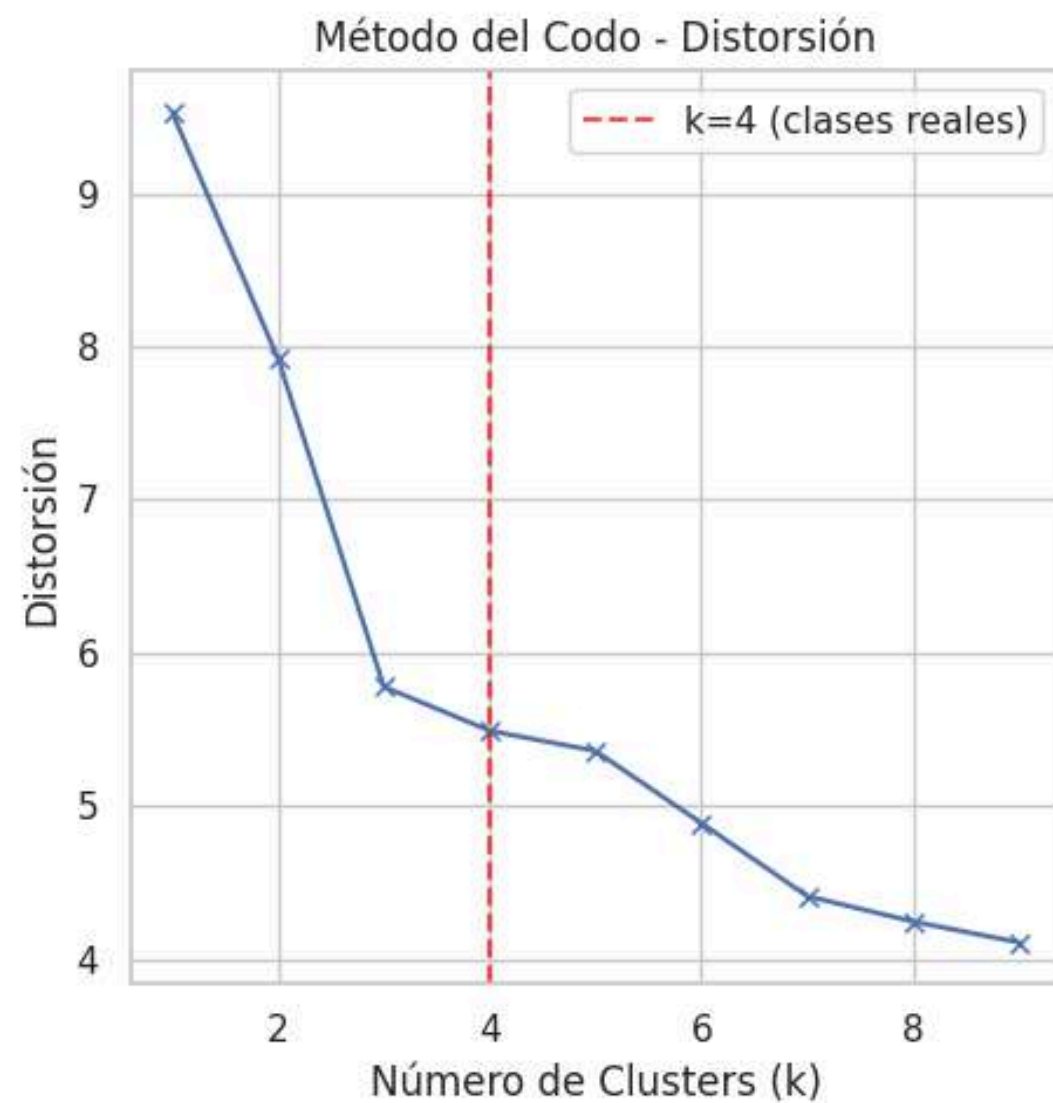
COMPARACIÓN: ARI SCORE



Representacion Grafica



Metodo del codo



INTERPRETACIÓN DEL MÉTODO DEL CODO:

- Inercia con $k=4$: 135712.28
- ¿El codo sugiere $k=4$? → NO - el codo sugiere otro k
Pero $k=4$ está justificado por las clases biológicas reales



**Thank you
for your
attention**